Settings

LLM Provider

- id — UUID, wymagane, unikalne
- provider_name — String, wymagane (Anthropic, OpenAI, Google)
- provider_api_endpoint — URL, wymagane
- provider_api_key_required — Boolean, wymagane
- #llm_models (1:N) — Modele od tego providera
- created_at — DataTime, auto
- updated_at — DataTime, auto

LLM Model

- id — UUID, wymagane, unikalne
- model_id — String, wymagane (claude-sonnet-4-5-20250929)
- model_display_name — String, wymagane (Claude Sonnet 4.5)
- model_tier — Enum, wymagane ("Tier1", "Tier2"))
- model_capabilities_flags — List<String>, opcjonalne (Do filtrowania np. Finanse, HR)
- #llm_provider_id (N:1) — UUID, wymagane, foreign key Należy do provider
- model_contex_window — Integer, wymagane Maksymalna liczba tokenów
- model_supports_thinking — Boolean, wymagane Czy wspiera extended thinking
- model_pricing_config — JSONB, wymagane (input_1M: 2.50, output_1M: 10.00)
- created_at — DataTime, auto
- updated_at — DataTime, auto

LLM Router

- id — UUID, wymagane, unikalne
- router_alias — String, wymagane, unikalne (Fast Response, Deep Thinking)
- router_strategy — Enum, wymagane (Cost_Optimized, Speed Optimization Quality Optimized)
- router_max_tokens_threshold — Integer, opcjonalne Przełącz na fallback jeśli przkroczony
- router_cost_limit_per_request — Decimal, opcjonalne
- #primary_model_id (N:1) — UUID, wymagane, foreign key Domyślny Model
- #fallback_model_id (N:1) — UUID, opcjonalne, foreign key Zapasowy model
- created_at — DataTime, auto
- updated_at — DataTime, auto

Embedding Model

- id — UUID, wymagane, unikalne
- model_provider_name — Enum, wymagane (Google, OpenAI...)
- model_id — String, wymagane (gemini-embedding-001)
- model_vector_dimensions — Integer, wymagane (786, 1520)
- model_max_context_tokens — Integer, wymagane (8191)
- model_cost_per_1m_tokens — String, wymagane ($ 0.02 / 1M tokenów)
- created_at — DataTime, auto
- updated_at — DataTime, auto

Chunking Strategy

- id — UUID, wymagane, unikalne
- strategy_name — String, wymagane General Text
- strategy_chunking_method — Enum, wymagane (Recursive_Character, Code_Splitter)
- strategy_chunk_size — Integer, wymagane (1000 - "Chunk Size (Wielkość): 1000 znaków")
- strategy_chunk_overlap — Integer, wymagane (200 - "Chunk Overlap (Nakładka): 1000 znaków")
- strategy_chunk_boundaries — List<String> / JSONB (["\n\n", "\n", " "])
- created_at — DataTime, auto
- updated_at — DataTime, auto

Vector Database

- id — UUID, wymagane, unikalne
- vector_database_type — Enum, wymagane (Postgres_pgvector, ChromaDB, Pinecone)
- vector_database_connection_url — String, wymagane (Host: aws-eu-central-1)
- vector_database_name — String, wymagane (Postgres - pgvector)
- vector_database_connecting_string — String, wymagane (axon_knowledge_vectors_)
- vector_database_collection_name — String, wymagane (axon_knowledge_vectors_1536)
- vector_database_index_method — Enum, wymagane (HNSW_Fast_More_RAM, IVFFLAT_Slower)
- vector_database_connection_status — Enum, wymagane (Connected, Disconnected)
- vector_database_size — String, computed (45 MB)
- vector_database_expected-dimensions — Integer, wymagane (Walidacja spójności z Embedding Model)
- vector_database_embedding_model_referen... — String, wymagane (text-embedding-3-small)
- vector_database_total_vectors — Integer, computed (450,200 wektorów)
- created_at — DataTime, auto
- updated_at — DataTime, auto

Text Chunk

- id — UUID, wymagane, unikalne
- chunk_index — Integer, wymagane Pozycja w źródłowym dokumencie
- chunk_text — Text, wymagane Fragment dokumentu
- chunk_embedding — Vector, wymagane Wektoryzowana reprezentacja
- chunk_metadata — JSON, opcjonalnie (page: 5, section: introduction)
- #knowledge_source_id (N:1) — UUID, wymagane, foreign key Należy do Knowledge Source
- chunk_token_count — Integer, opcjonalne (Dla cost tracking)
- created_at — DataTime, auto